

Обучение с подкреплением,
метаэвристики и нейроэволюция

Практическая работа №1.

Табличные агенты (рациональный, поведенческий и
риск-чувствительный) для задачи навигации дрона

Содержание

1	Цель и постановка задачи	3
2	Общая MDP-формализация (общая для всех вариантов)	3
2.1	Состояние	3
2.2	Действия	3
2.3	Эпизоды и критерии завершения	4
2.4	Препятствия и коллизии	4
3	Целевые методы (краткое математическое описание)	4
3.1	Метод 1: рациональный табличный Q-learning	4
3.2	Метод 2: поведенческий агент (Prospect Theory Q-learning)	5
3.3	Метод 3: риск-чувствительный агент (энтропийный risk-sensitive Q-learning)	6
4	Протокол обучения и оценки	7
4.1	Дискретизация пространства состояний	7
4.2	Обучение	7
4.3	Тестирование	7
5	Вариант 1: турбулентный ветер и 4 препятствия	8
5.1	Геометрия	8
5.2	Состояния и действия	8
5.3	Динамика	8
5.4	Терминальные условия	8
5.5	Награда	8
5.6	Схема среды	9
6	Вариант 2: анизотропный ветер и 5 препятствий	10
6.1	Геометрия	10
6.2	Состояния и действия	10
6.3	Динамика	10
6.4	Терминальные условия	10
6.5	Награда	10
6.6	Схема среды	11
7	Техническое задание	12

1 Цель и постановка задачи

Рассматривается задача управления автономным дроном в двумерном пространстве $\mathcal{X} = [0, 20] \times [0, 10] \subset \mathbb{R}^2$. Целью дрона является достижение станции быстрой зарядки при максимизации накопленного вознаграждения с учетом стохастического ветра, энергопотребления и статичных препятствий.

Цель лабораторной работы: реализовать среду управления дроном и сравнить три табличных RL-агента:

1. рациональный табличный Q-learning (risk-neutral);
2. поведенческий табличный Q-learning с трансформацией вознаграждения по теории перспектив;
3. риск-чувствительный табличный Q-learning на основе энтропийной (экспоненциальной) полезности.

Результат выполнения: код среды, код трёх агентов, отчёт по экспериментам (метрики и визуализации), статистическое сравнение.

2 Общая MDP-формализация (общая для всех вариантов)

Среда задаётся конечным марковским процессом принятия решений (MDP) [5]

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma), \quad (1)$$

где $\mathcal{S}$ — множество дискретизированных состояний, $\mathcal{A}$ — конечное множество действий, $P(s' | s, a)$ — вероятностная функция переходов, $R(s, a, s')$ — функция награды, $\gamma \in (0, 1)$ — коэффициент дисконтирования.

2.1 Состояние

Состояние агента задаётся 4-мерным вектором

$$s_t = (\Delta x_t, \Delta y_t, b_t, v_t), \quad (2)$$

где $(\Delta x_t, \Delta y_t)$ — относительное смещение до центра станции зарядки, $b_t \in [0, 1]$ — нормированный заряд батареи, v_t — наблюдаемая скорость, принимающая значения из заданного множества (по варианту).

2.2 Действия

Действия дискретны и задают пару (направление, целевая скорость):

$$a_t \equiv (\theta_t, \tilde{v}_t), \quad (3)$$

где $\theta_t \in \{0, \frac{\pi}{2}, \pi, \frac{3\pi}{2}\}$, а $\tilde{v}_t$ выбирается из укороченного множества скоростей. Одна из скоростей считается достижимой только динамически (т.е. присутствует в состоянии, но отсутствует как отдельное действие) для сокращения мощности $|\mathcal{A}|$.

2.3 Эпизоды и критерии завершения

Эпизод завершается при выполнении одного из условий: (i) успех (вход в область станции и достижение порога заряда); (ii) провал (критически низкий заряд); (iii) превышение лимита шагов.

2.4 Препятствия и коллизии

Пространство содержит прямоугольные препятствия. При попытке пересечения препятствия применяется выбранная модель коллизии:

- **Запрет входа:** позиция не обновляется, фиксируется событие коллизии;
- **Проекция на границу:** следующая позиция проектируется на ближайшую точку границы прямоугольника.

Выбранная модель коллизии должна быть одинаковой во всех сравниваемых агентах.

3 Целевые методы (краткое математическое описание)

Все три агента работают в одной и той же дискретной MDP-среде и различаются не динамикой среды, а способом оценки полезности последствий действия. Введём кумулятивную дисконтированную награду (discounted cumulative reward):

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}, \quad (4)$$

где r_{t+k+1} — награда, полученная после применения действия на k -м шаге от момента t . Для всех методов используется одна и та же таблица значений по всем парам (s, a) , одинаковое множество действий и единая схема исследования пространства состояний.

3.1 Метод 1: рациональный табличный Q-learning

Рациональный агент соответствует классической риск-нейтральной постановке: он максимизирует математическое ожидание дисконтированной награды [1, 5]. Для фиксированной политики π функция действия-ценности задаётся как

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]. \quad (5)$$

Оптимальная функция $Q^*(s, a)$ удовлетворяет уравнению оптимальности Беллмана

$$Q^*(s, a) = \mathbb{E}[r_{t+1} + \gamma \max_{a'} Q^*(s_{t+1}, a') \mid s_t = s, a_t = a]. \quad (6)$$

Табличный Q-learning строит стохастическое приближение к Q^* по наблюдаемым переходам $(s_t, a_t, r_{t+1}, s_{t+1})$ [2, 1]. На каждом шаге вычисляется однокроковая TD-цель

$$y_t^{(Q)} = r_{t+1} + \gamma \max_{a'} Q_t(s_{t+1}, a'), \quad (7)$$

и TD-ошибка

$$\delta_t^{(Q)} = y_t^{(Q)} - Q_t(s_t, a_t). \quad (8)$$

После этого выполняется обновление

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha_t \delta_t^{(Q)}, \quad (9)$$

а для всех остальных пар $(s, a) \neq (s_t, a_t)$ значение сохраняется:

$$Q_{t+1}(s, a) = Q_t(s, a). \quad (10)$$

Параметр $\alpha_t \in (0, 1]$ определяет скорость обучения: при малом α_t обновления устойчивее, но адаптация идёт медленнее. Коэффициент $\gamma \in (0, 1)$ задаёт горизонт планирования: чем ближе γ к 1, тем сильнее агент учитывает отдалённые последствия текущего действия. В контексте задачи навигации это означает, что агент учится выбирать действия не только по немедленному выигрышу, но и по их влиянию на дальнейшее достижение станции зарядки, риск столкновений и расход энергии.

Политика выбора действий строится по правилу ε -greedy:

$$a_t = \begin{cases} \text{случайное действие из } \mathcal{A}, & \text{с вероятностью } \varepsilon_t, \\ \arg \max_{a \in \mathcal{A}} Q_t(s_t, a), & \text{с вероятностью } 1 - \varepsilon_t. \end{cases} \quad (11)$$

Затухание ε_t обеспечивает переход от исследования к эксплуатации [1]. Таким образом, рациональный агент служит базовой линией сравнения: он оценивает действия по их среднему ожидаемому эффекту без специального учёта асимметрии выигрышей и потерь и без явной модификации отношения к риску.

3.2 Метод 2: поведенческий агент (Prospect Theory Q-learning)

Во втором методе меняется способ восприятия подкрепления. Мотивация состоит в том, что реальный субъект часто оценивает потери и выигрыши несимметрично: потери ощущаются сильнее равных по модулю выигрышей, а сама шкала полезности нелинейна [3, 4]. В лабораторной работе это моделируется через функцию ценности теории перспектив

$$v(r) = \begin{cases} r^{\alpha_p}, & r \geq 0, \\ -\lambda_p(-r)^{\beta_p}, & r < 0, \end{cases} \quad (12)$$

где $\alpha_p, \beta_p \in (0, 1]$ отвечают за вогнутость/выпуклость функции в области выигрышей и потерь, а $\lambda_p > 1$ задаёт коэффициент неприятия потерь.

При $\alpha_p < 1$ положительные награды сжимаются: крупные выигрыши растут медленнее. При $\beta_p < 1$ отрицательные награды также меняются нелинейно. Коэффициент λ_p делает штрафы более «тяжёлыми» по сравнению с равными по модулю положительными наградами. В контексте текущей задачи это означает, что столкновение, избыточный расход энергии или неудачный манёвр могут существенно сильнее влиять на обучение, чем эквивалентный по величине локальный выигрыш.

После преобразования награды определяется prospect-theoretic TD-цель [8]

$$y_t^{(PT)} = v(r_{t+1}) + \gamma \max_{a'} Q_t(s_{t+1}, a'), \quad (13)$$

и соответствующая ошибка

$$\delta_t^{(PT)} = y_t^{(PT)} - Q_t(s_t, a_t). \quad (14)$$

Обновление таблицы имеет вид

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha_t \delta_t^{(PT)}. \quad (15)$$

С математической точки зрения данный метод сохраняет структуру классического Q-learning, однако работает не с исходной наградой r_{t+1} , а с её субъективной оценкой $v(r_{t+1})$. Поэтому агент фактически приближает оптимальные значения в задаче с модифицированным одномоментным критерием. Если рациональный агент обучается на «объективной» шкале наград, то поведенческий агент обучается на поведенчески искажённой шкале. В результате его стратегия может становиться более осторожной вблизи препятствий, при низком заряде батареи или в ситуациях, где возможны крупные штрафы, даже если среднее ожидаемое вознаграждение формально совпадает с базовым методом.

Практически важно, что при слишком больших λ_p или слишком малых α_p, β_p преобразование награды может сделать обучение более шумным и замедлить сходимость, поскольку различия между действиями начинают определяться главным образом редкими штрафными событиями. Поэтому параметры функции $v(r)$ должны быть выбраны и затем зафиксированы одинаково для всех сценариев сравнения.

3.3 Метод 3: риск-чувствительный агент (энтропийный risk-sensitive Q-learning)

Третий метод меняет уже не только одномоментную награду, а сам критерий оптимальности. Вместо максимизации ожидаемого возврата рассматривается энтропийная (экспоненциальная) полезность [6, 7]

$$J_\eta(\pi) = -\frac{1}{\eta} \log \mathbb{E}_\pi [\exp(-\eta G_t)], \quad \eta \neq 0. \quad (16)$$

Параметр η управляет отношением к риску:

- при $\eta > 0$ агент риск-аверсивен и сильнее штрафует траектории с неблагоприятными исходами;
- при $\eta < 0$ агент был бы риск-предпочитающим;
- при пределе $\eta \rightarrow 0$ критерий переходит в риск-нейтральный случай, то есть в максимизацию $\mathbb{E}[G_t]$.

Энтропийный критерий чувствителен не только к среднему возврату, но и к его разбросу. Для малых $|\eta|$ справедлива асимптотика

$$J_\eta(\pi) \approx \mathbb{E}_\pi[G_t] - \frac{\eta}{2} \text{Var}_\pi(G_t), \quad (17)$$

из которой видно, что при $\eta > 0$ агент штрафует большую дисперсию возврата. Это особенно релевантно для среды со стохастическим ветром: два действия могут иметь близкий средний эффект, но одно из них может иногда приводить к тяжёлым потерям из-за сноса в препятствие или преждевременного разряда батареи.

Для табличной реализации удобно перейти к экспоненциально преобразованной функции

$$U(s, a) = \exp(-\eta Q(s, a)), \quad (18)$$

после чего риск-чувствительное уравнение Беллмана принимает мультипликативную форму [7]. Для наблюдаемого перехода $(s_t, a_t, r_{t+1}, s_{t+1})$ используется целевое значение

$$y_t^{(U)} = \exp(-\eta r_{t+1}) \cdot \left(\min_{a'} U_t(s_{t+1}, a') \right)^\gamma, \quad (19)$$

и обновление

$$U_{t+1}(s_t, a_t) = (1 - \alpha_t)U_t(s_t, a_t) + \alpha_t y_t^{(U)}. \quad (20)$$

Для остальных пар состояний и действий значения сохраняются без изменений. После обновления выполняется обратное преобразование

$$Q_{t+1}(s, a) = -\frac{1}{\eta} \log U_{t+1}(s, a). \quad (21)$$

Минимум по a' в U -пространстве эквивалентен максимуму по Q -значениям, поскольку при $\eta > 0$ функция $\exp(-\eta x)$ монотонно убывает по x . Поэтому политика выбора действий по-прежнему может строиться в Q -пространстве:

$$a_t = \begin{cases} \text{случайное действие,} & \text{с вероятностью } \varepsilon_t, \\ \arg \max_{a \in \mathcal{A}} Q_t(s_t, a), & \text{с вероятностью } 1 - \varepsilon_t. \end{cases} \quad (22)$$

Главное отличие от двух предыдущих методов состоит в том, что риск-чувствительный агент штрафует не по отдельным отрицательным наградам, а по целым траекториям с неблагоприятным распределением итогового возврата. Иными словами, поведенческий агент искажает локальное подкрепление, а риск-чувствительный агент меняет глобальный критерий качества политики. В задачах навигации это обычно приводит к выбору более устойчивых маршрутов, которые могут быть немного длиннее по среднему времени, но обладают меньшей вероятностью полного провала задачи.

4 Протокол обучения и оценки

4.1 Дискретизация пространства состояний

Необходимо задать равномерные или квазирегулярные разбиения по координатам $(\Delta x, \Delta y)$, заряду b и скорости v . Дискретизация должна совпадать для всех трёх агентов в рамках одного варианта.

4.2 Обучение

- Обучение каждого агента: 15 000 эпизодов.
- ε -greedy: $\varepsilon_0 = 1.0 \rightarrow \varepsilon_{\min} = 0.01$, коэффициент затухания 0.997.
- Рекомендуемый γ : 0.99.
- Логирование: суммарная награда, длина эпизода, число коллизий, финальный заряд.

4.3 Тестирование

- 300 тестовых эпизодов на агента при $\varepsilon = 0.005$.
- Метрики: успех (%), среднее время до успеха, средний расход энергии, коллизии (% эпизодов).
- Визуализации: кривая обучения (скользящее окно 150), CDF времени успеха, heatmap финального заряда, 4 траектории каждого агента.
- Статистика: t-test по выбранной числовой метрике с уровнем значимости $p < 0.05$.

5 Вариант 1: турбулентный ветер и 4 препятствия

5.1 Геометрия

- Пространство: $\mathcal{X} = [0, 24] \times [0, 12]$.
- Станция зарядки: центр $(21.5, 8.5)$, радиус 0.9, мощность $P_{\text{charge}} = 0.025$ на шаг.
- Старт: $(x_0, y_0) \sim \mathcal{N}((3.5, 6.0), \sigma^2 I)$, $\sigma = 1.8$; клип: $x \in [1.0, 7.0]$, $y \in [2.0, 10.0]$.
- Ветер: $w_t = (w_x, w_y)$, $w_x, w_y \sim \mathcal{U}(-0.11, 0.11)$; обновление каждые 15 шагов.
- Препятствия: $O_1 : (10.0, 2.0) - (11.5, 5.5)$, $O_2 : (13.0, 7.0) - (14.5, 10.0)$, $O_3 : (16.5, 3.5) - (18.0, 6.5)$, $O_4 : (19.0, 9.0) - (20.5, 11.5)$.

5.2 Состояния и действия

- Скорости: $v \in \{0.10, 0.25, 0.40, 0.60\}$.
- Дискретизация: $14 \times 14 \times 12 \times 4 = 9408$ состояний.
- Действия: 16 дискретных (4 направления $\times$ 3 целевые скорости + служебные комбинации по спецификации реализации).

5.3 Динамика

$$x_{t+1} = x_t + v_t \cos \theta_t + w_{x,t}, \quad (23)$$

$$y_{t+1} = y_t + v_t \sin \theta_t + w_{y,t}. \quad (24)$$

$$b_{t+1} = \min \left(1, b_t - 0.018v_t^2 - 0.003\|w_t\|^2 - 0.002|v_t| + \mathbb{I}_{\text{station}} \cdot 0.025 \right). \quad (25)$$

5.4 Терминальные условия

- Успех: $\|(x_t, y_t) - (21.5, 8.5)\| < 0.9$ и $b_t > 0.90$ при $t \leq 140$.
- Провал: $b_t < 0.04$ или $t \geq 200$.

5.5 Награда

$$r_t = \begin{cases} +90, & \text{успех,} \\ -170, & \text{разряд,} \\ -1.0 - 0.030v_t^2 + 0.12 \cdot 0.025 \cdot \mathbb{I}_{\text{station}}, & \text{иначе.} \end{cases} \quad (26)$$

5.6 Схема среды




Рис. 1: Вариант 1: конфигурация среды. Условные обозначения: заштрихованные прямоугольники — препятствия O_i ; окружность — область станции зарядки; точка μ — среднее начальной позиции; пунктирная эллипса — область 2σ начальной позиции; штрихпунктирный прямоугольник — область усечения начальной позиции.

6 Вариант 2: анизотропный ветер и 5 препятствий

6.1 Геометрия

- Пространство: $\mathcal{X} = [0, 26] \times [0, 14]$.
- Станция зарядки: центр $(23.0, 4.5)$, радиус 1.0, мощность $P_{\text{charge}} = 0.030$ на шаг.
- Старт: $(x_0, y_0) \sim \mathcal{N}((4.0, 10.0), \sigma^2 I)$, $\sigma = 2.0$; клип: $x \in [1.5, 8.0]$, $y \in [4.0, 13.0]$.
- Ветер (анизотропный): $w_x \sim \mathcal{U}(-0.14, 0.05)$, $w_y \sim \mathcal{U}(-0.07, 0.12)$; обновление каждые 25 шагов.
- Препятствия: $O_1 : (9.0, 3.0) - (10.5, 8.0)$, $O_2 : (12.0, 10.0) - (14.0, 12.5)$, $O_3 : (15.5, 2.0) - (17.5, 6.0)$, $O_4 : (18.0, 7.5) - (20.0, 11.0)$, $O_5 : (21.0, 1.0) - (22.5, 3.5)$.

6.2 Состояния и действия

- Скорости: $v \in \{0.12, 0.28, 0.45, 0.65\}$.
- Дискретизация: $15 \times 15 \times 10 \times 4 = 9000$ состояний.
- Действия: 16 дискретных (4 направления $\times$ 3 целевые скорости + служебные комбинации по спецификации реализации).

6.3 Динамика

$$x_{t+1} = x_t + v_t \cos \theta_t + 0.8 w_{x,t}, \quad (27)$$

$$y_{t+1} = y_t + v_t \sin \theta_t + 1.2 w_{y,t}. \quad (28)$$

$$b_{t+1} = \min \left(1, b_t - 0.020 v_t^2 - 0.004 |w_{x,t}| - 0.003 |w_{y,t}| + \mathbb{I}_{\text{station}} \cdot 0.030 \right). \quad (29)$$

6.4 Терминальные условия

- Успех: $\|(x_t, y_t) - (23.0, 4.5)\| < 1.0$ и $b_t > 0.88$ при $t < 150$.
- Провал: $b_t < 0.03$ или $t > 210$.

6.5 Награда

$$r_t = \begin{cases} +100, & \text{успех,} \\ -180, & \text{разряд,} \\ -1.2 - 0.035 v_t^2 + 0.15 \cdot 0.030 \cdot \mathbb{I}_{\text{station}}, & \text{иначе.} \end{cases} \quad (30)$$

6.6 Схема среды




Рис. 2: Вариант 2: конфигурация среды. Условные обозначения: заштрихованные прямоугольники — препятствия O_i ; окружность — область станции зарядки; точка μ — среднее начальной позиции; пунктирная эллипса — область 2σ начальной позиции; штрихпунктирный прямоугольник — область усечения начальной позиции.

7 Техническое задание

А. Среда

1. Реализовать двумерную среду с ограниченной областью движения и клипом координат.
2. Реализовать обновление ветра с заданным периодом; сохранять ветер постоянным между обновлениями.
3. Реализовать препятствия-прямоугольники и учёт коллизий (с фиксированным правилом).
4. Реализовать нелинейный расход батареи и зарядку в зоне станции.
5. Реализовать дискретизацию состояния в соответствии с вариантом.

В. Агенты

1. Реализовать рациональный Q-learning (таблично) + ε -greedy.
2. Реализовать поведенческий Q-learning с $v(r)$ (Prospect Theory):
 $(\alpha_p, \beta_p, \lambda_p) = (0.88, 0.88, 2.35)$.
3. Реализовать риск-чувствительный (энтропийный) агент:
выбрать $\eta \in \{0.5, 1.0, 2.0\}$ и обосновать выбор.

С. Эксперименты

1. Обучение: 15 000 эпизодов на агента; одинаковые значения γ , α , расписание ε .
2. Тестирование: 300 эпизодов на агента при $\varepsilon = 0.005$.
3. Метрики: успех(%), время до успеха, расход энергии, коллизии(%).
4. Визуализация: learning curve (окно 150), CDF времени успеха, heatmap финального заряда, траектории (минимум по 4 на агента).
5. Статистика: t-test по времени успеха (или расходу энергии) с уровнем значимости $p < 0.05$.

Д. Вариант

Вариант выбирается исходя из четности/нечетности порядкового номера студента в группе.

Е. Отчет

Отчет по результатам работы должен содержать полноценный исследовательский анализ. В отчете должны присутствовать разделы отражающие ход работы, детали имплементации, результаты численных экспериментов и все необходимые визуализации.

Список литературы

- [1] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. 2nd ed. MIT Press, 2018. URL: <http://incompleteideas.net/book/the-book-2nd.html>
- [2] C. J. C. H. Watkins and P. Dayan. Q-learning. *Machine Learning*, 8(3–4):279–292, 1992. DOI: <https://doi.org/10.1007/BF00992698>
- [3] D. Kahneman and A. Tversky. Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, 47(2):263–291, 1979. DOI: <https://doi.org/10.2307/1914185>
- [4] A. Tversky and D. Kahneman. Advances in Prospect Theory: Cumulative Representation of Uncertainty. *Journal of Risk and Uncertainty*, 5(4):297–323, 1992. DOI: <https://doi.org/10.1007/BF00122574>
- [5] M. L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley, 1994.
- [6] R. A. Howard and J. E. Matheson. Risk-sensitive Markov decision processes. *Management Science*, 18(7):356–369, 1972. DOI: <https://doi.org/10.1287/mnsc.18.7.356>
- [7] V. S. Borkar. Q-learning for risk-sensitive control. *Mathematics of Operations Research*, 27(2):294–311, 2002. DOI: <https://doi.org/10.1287/moor.27.2.294.342>
- [8] V. S. Borkar and S. Chandak. Prospect-theoretic Q-learning. *Systems & Control Letters*, 156:105009, 2021. DOI: <https://doi.org/10.1016/j.sysconle.2021.105009>