

**TOMSK
POLYTECHNIC
UNIVERSITY**



**ТОМСКИЙ
ПОЛИТЕХНИЧЕСКИЙ
УНИВЕРСИТЕТ**

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский Томский политехнический университет» (ТПУ)

Школа: **Инженерная школа информационных технологий и робототехники**
Направление подготовки: **09.04.01 Информатика и вычислительная техника**
Отделение школы (НОЦ): **Отделение информационных технологий**

Практическая работа №1
по дисциплине
Обучение с подкреплением, метаэвристики и нейроэволюция

Тема задания
Табличные агенты (рациональный, поведенческий и риск-чувствительный) для задачи навигации дрона

Студент

Группа	ФИО	Подпись	Дата
8BM52	Фань Синьюэ		15.04.2026

Преподаватель

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Старший преподаватель ОИТ, ИШИТР	Григорьев Д. С.			

Введение

Цель работы состояла в реализации двумерной среды навигации дрона и в сравнении трёх табличных агентов обучения с подкреплением: рационального Q-learning, поведенческого агента на основе Prospect Theory и риск-чувствительного агента на основе энтропийной полезности. Эксперимент выполнялся для варианта 1 методических указаний, где движение осложняется турбулентным ветром, наличием четырёх прямоугольных препятствий и ограниченным зарядом батареи.

В отчёте приведены описание среды, детали реализации агентов, параметры обучения и тестирования, численные результаты, статистическое сравнение и интерпретация полученных графиков. Все основные вычисления выполнены в табличной постановке, а сравнение агентов проводилось в одной и той же дискретизированной среде.

1. Постановка задачи и параметры варианта 1

Согласно методическим указаниям, для варианта 1 рабочее пространство задаётся прямоугольником $X = [0, 24] \times [0, 12]$, станция зарядки имеет центр (21.5, 8.5) и радиус 0.9, а стартовая позиция дрона генерируется из нормального распределения с математическим ожиданием (3.5, 6.0) и $\sigma = 1.8$ с последующим отсечением по $x \in [1.0, 7.0]$ и $y \in [2.0, 10.0]$. Ветер является турбулентным: обе компоненты выбираются из равномерного распределения $U(-0.11, 0.11)$ и обновляются каждые 15 шагов.

Состояние среды описывается вектором $s_t = (\Delta x_t, \Delta y_t, b_t, v_t)$, где Δx_t и Δy_t — смещение до центра станции, $b_t \in [0, 1]$ — нормированный заряд батареи, v_t — наблюдаемая скорость. В реализации использована дискретизация $14 \times 14 \times 12 \times 4$, что даёт 9408 дискретных состояний. В данной реализации использовано 16 действий: 4 ортогональных направления $\times$ 4 допустимых значения скорости.

Эпизод завершается в одном из трёх случаев: при успехе (дрон входит в область станции и сохраняет заряд выше 0.90 не позднее 140-го шага), при провале из-за критического разряда батареи ($b < 0.04$) или при достижении лимита по времени ($t \geq 200$). Награда задаётся следующим образом: +90 за успешное завершение, -170 за разряд батареи и шаговая награда $-1.0 - 0.030 \cdot v_t^2 + 0.12 \cdot 0.025 \cdot I_{station}$ во всех остальных состояниях.

5.6 Схема среды




Рис. 1: Вариант 1: конфигурация среды. Условные обозначения: заштрихованные прямоугольники — препятствия O_i ; окружность — область станции зарядки; точка μ — среднее начальной позиции; пунктирная эллипса — область 2σ начальной позиции; штрихпунктирный прямоугольник — область усечения начальной позиции.

Рисунок 1 — Конфигурация среды для варианта 1

2. Реализация среды

Среда реализована в классе `DroneEnv`. Координаты дрона ограничиваются операцией `clip` по x и y , что исключает выход за допустимые границы области. Для моделирования столкновений с препятствиями использовано правило «запрет входа»: если отрезок между текущей и предполагаемой следующей позицией пересекает прямоугольное препятствие, координаты дрона не обновляются, а событие коллизии фиксируется во внутренней статистике среды.

Энергопотребление задаётся нелинейной формулой, зависящей от

квадрата скорости, квадрата нормы ветра и линейного штрафа по модулю скорости. При нахождении дрона в зоне станции к заряду добавляется фиксированная величина $\text{charge_power} = 0.025$. Такая модель соответствует техническому заданию и одинакова для всех сравниваемых агентов, что обеспечивает корректность последующего сравнения.

Начальный заряд батареи в реализации задаётся равным единице. В методических указаниях начальное значение явно не фиксируется, поэтому выбор полного заряда является естественным и позволяет сосредоточить анализ на различиях в политике движения, а не на различиях в стартовых условиях.

3. Реализация агентов

Рациональный агент использует стандартный табличный Q-learning и служит базовой линией сравнения. Обновление имеет вид $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$ для нетерминальных состояний и $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} - Q(s_t, a_t)]$ для терминальных переходов.

Поведенческий агент Prospect Q-learning заменяет непосредственную награду её субъективной оценкой $v(r)$. Для положительных наград используется степенная функция r^{α_p} , а для отрицательных — выражение $-\lambda_p(-r)^{\beta_p}$. В работе использованы параметры $\alpha_p = 0.88$, $\beta_p = 0.88$ и $\lambda_p = 2.35$, заданные методическими указаниями.

Риск-чувствительный агент реализован через U-преобразование $U(s, a) = \exp(-\eta Q(s, a))$. В пространстве U обновление носит мультипликативный характер, после чего Q-величины восстанавливаются по формуле $Q(s, a) = -(1/\eta) \ln U(s, a)$. В качестве коэффициента риск-чувствительности выбрано значение $\eta = 0.5$. Такой выбор обеспечивает умеренную риск-аверсию и хорошую численную устойчивость: при более жёстких значениях η редкие крупные штрафы начинают доминировать над всеми остальными сигналами

подкрепления, что может ухудшать обучение в задаче с очень редкими успешными эпизодами.

Для всех агентов использована одинаковая оптимистическая инициализация $Q_0 = 5.0$. Это дополнительно стимулирует исследование пространства состояний на ранней стадии обучения. Выбор действий осуществляется по ϵ -greedy-схеме. В реализации при совпадении нескольких максимальных Q -значений используется дополнительное одинаковое для всех агентов tie-break-правило `one_step_lookahead_score`, которое предпочитает действие, уменьшающее расстояние до станции и не ведущее к коллизии. Таким образом, базовый механизм выбора действия остаётся ϵ -greedy, а дополнительная эвристика используется только для разрешения равенства между лучшими действиями.

4. Протокол эксперимента

Эксперимент проводился в два этапа. Сначала выполнялся `smoke-test` на сокращённом числе эпизодов (2000 обучающих и 100 тестовых) для быстрой проверки корректности среды и процедур обучения. После этого запускался основной эксперимент: по 15 000 обучающих эпизодов на каждого агента и по 300 тестовых эпизодов при $\epsilon = 0.005$.

Общие параметры обучения были одинаковыми для всех агентов: $\gamma = 0.99$, $\alpha = 0.10$, $\epsilon_0 = 1.0$, $\epsilon_{\min} = 0.01$, коэффициент затухания ϵ равен 0.997. Во время обучения логировались суммарная награда эпизода, его длина, число коллизий, финальный заряд батареи и текущее значение ϵ . Во время тестирования дополнительно сохранялись финальные координаты, расход энергии и траектории отдельных запусков.

Для обеспечения корректности межагентного сравнения тестовые эпизоды синхронизировались по одинаковому `seed_base = 3000`. Это означает, что разные агенты оценивались на одной и той же последовательности стартовых положений и реализаций ветра.

5. Основные фрагменты реализации

Ниже приведены ключевые фрагменты кода.

Листинг 1 — Конфигурация эксперимента.

```
SEED = 42
COMMON_CFG = {
    "num_train_episodes": 15000,
    "num_test_episodes": 300,
    "gamma": 0.99,
    "alpha": 0.10,
    "epsilon_start": 1.0,
    "epsilon_min": 0.01,
    "epsilon_decay": 0.997,
    "test_epsilon": 0.005,
    "prospect_alpha": 0.88,
    "prospect_beta": 0.88,
    "prospect_lambda": 2.35,
    "risk_eta": 0.5,
    "optimistic_q0": 5.0,
}
```

Листинг 2 — Логика шага среды.

```
def step(self, action_idx):
    self._refresh_wind_if_needed()
    theta, target_v = self.actions[action_idx]
    collision = self._apply_dynamics(theta, target_v)
    in_station = self.is_in_station(self.x, self.y)
    energy_use, charge_gain = self._battery_update(in_station)
    self.t += 1
    success = self._is_success(in_station)
    battery_fail = (self.b < self.cfg["failure_battery_threshold"])
    time_fail = self._is_time_fail()
    ...
    return self.get_state_index(), reward, done, info
```

Листинг 3 — Обновления для Prospect Q-learning и риск-чувствительного агента.

```
def value_function(self, r):
    if r >= 0:
        return r ** self.alpha_p
    return -self.lambda_p * ((-r) ** self.beta_p)

def update(self, state, action, reward, next_state, done):
    subjective_reward = self.value_function(reward)
    if done:
        target = subjective_reward
    else:
        target = subjective_reward + self.gamma * np.max(self.Q[next_state])
    self.Q[state, action] += self.alpha * (target - self.Q[state, action])

def update(self, state, action, reward, next_state, done):
    old_u = self.U[state, action]
    if done:
        log_target_u = -self.eta * reward
    else:
        min_next_u = max(np.min(self.U[next_state]), 1e-300)
        log_target_u = -self.eta * reward + self.gamma * np.log(min_next_u)
        target_u = np.exp(np.clip(log_target_u, -700, 700))
        self.U[state, action] = np.clip((1.0 - self.alpha) * old_u + self.alpha *
target_u, 1e-300, 1e300)
        self.Q[state, action] = -(1.0 / self.eta) * np.log(self.U[state, action])
```

6. Результаты эксперимента

6.1. Проверка корректности среды

На этапе первичной проверки были выведены базовые характеристики среды: число состояний, число действий и несколько первых шагов случайной траектории. Проверка показала, что среда содержит 9408 состояний и 16 действий, а батарея и награда изменяются в соответствии с ожидаемой логикой.

Краткий фрагмент вывода программы:

```
Текущая схема: Scheme 1
Тренировочных эпизодов: 15000
Тестовых эпизодов: 300
state bins: (14, 14, 12, 4)
speeds: [0.1, 0.25, 0.4, 0.6]
Начальный индекс состояния: 8540
Число состояний: 9408
Число действий: 16
step=1, action=6, reward=-1.005, battery=0.996, done=False
step=2, action=3, reward=-1.011, battery=0.989, done=False
step=3, action=12, reward=-1.000, battery=0.988, done=False
```

6.2. Smoke-test

Сокращённый запуск подтвердил работоспособность всей цепочки обучения и тестирования. Уже на этом этапе было видно, что задача достаточно трудная: рациональный агент не демонстрировал успешных эпизодов, Prospect-агент достигал 2 % успеха, а риск-чувствительный агент — 4 % успеха при 100 тестовых эпизодах. Эти результаты стали основанием для проведения полного эксперимента без изменения структуры среды.

Таблица 1 — Результаты smoke-test

Агент	Успех, %	Средняя длина	Средний расход энергии	Коллизии, %	Средний финальный заряд
Rational	0.0	200.00	0.4815	9.0	0.5185
Prospect	2.0	197.21	0.5474	45.0	0.4605
Risk-sensitive	4.0	195.54	0.4591	30.0	0.5506

6.3. Основной эксперимент

После полного обучения были получены агрегированные показатели, приведённые в таблице 2. Лучший результат по основной метрике успеха показал Prospect Q-learning: 8 % успешных эпизодов из 300 и среднее время достижения станции 66.79 шага среди успешных запусков. Среднее время успеха вычислялось только по успешным эпизодам; для рационального и риск-чувствительного агентов в итоговом прогоне эта метрика не определялась из-за отсутствия успешных завершений. Рациональный и риск-чувствительный агенты в финальном прогоне не показали успешных эпизодов.

Таблица 2 — Итоговые метрики на 300 тестовых эпизодах

Агент	Успех, %	Среднее время успеха	Средний расход энергии	Коллизии, %	Средний финальный заряд
Rational Q-learning	0.00	—	0.5180	31.33	0.4851
Prospect Q-learning	8.00	66.79	0.5107	40.00	0.5169
Risk-sensitive Q-learning	0.00	—	0.5672	33.67	0.4357

Полученные значения показывают, что поведенческая трансформация награды оказалась полезной именно в данной конфигурации среды: Prospect-агент чаще добирался до станции и в среднем тратил немного меньше энергии, чем рациональный агент. Риск-чувствительный агент, напротив, оказался слишком консервативным и не продемонстрировал успешного достижения цели в финальном тесте.

6.4. Статистическое сравнение

Методические указания допускают проведение t-теста либо по времени успеха, либо по расходу энергии. В данной работе корректный сравнительный тест был выполнен по метрике расхода энергии, так как время успеха

определено только для одного агента и при прямом сравнении даёт значения NaN.

Таблица 3 — Welch t-test по метрике расхода энергии

Сравнение	t-статистика	p-значение	Вывод
Rational vs Prospect	0.5635	0.573286	различие незначимо
Rational vs Risk-sensitive	-4.0884	4.9645e-05	различие значимо
Prospect vs Risk-sensitive	-4.7425	2.66375e-06	различие значимо

Таким образом, статистически значимые различия по расходу энергии обнаружены между риск-чувствительным агентом и двумя остальными агентами. Между рациональным и поведенческим агентами различие по этой метрике статистически не подтвердилось. Это согласуется с тем, что основное преимущество Prospect-агента в данном эксперименте проявилось не столько в энергопотреблении, сколько в способности иногда находить успешную траекторию к станции.

7. Анализ визуализаций

В ноутбуке были построены все визуализации, требуемые техническим заданием: learning curve со скользящим окном 150, эмпирическая функция распределения (CDF) времени успеха, тепловые карты финального заряда и траектории для трёх агентов. Ниже приведён содержательный анализ этих графиков.

Кривые обучения показывают, что усреднённая суммарная награда для всех трёх агентов на протяжении большей части обучения остаётся вблизи значения -201. Это означает, что во многих эпизодах дрон не успевает достичь станции и завершает эпизод по лимиту шагов, накапливая примерно одинаковый штраф за длину траектории. Редкие подъёмы кривой вверх соответствуют отдельным успешным или относительно удачным эпизодам, однако стабильного роста качества у рационального и риск-чувствительного

агентов не наблюдается.




Рисунок 2 — Кривые обучения табличных агентов (скользящее среднее суммарной награды, окно 150 эпизодов)

CDF времени успеха в итоговом прогоне была построена только для Prospect-агента, поскольку у двух других агентов успешные эпизоды отсутствовали. Форма кривой показывает, что успешные траектории у поведенческого агента встречаются в широком диапазоне длин — приблизительно от 42 до 121 шага, а медианная успешная длина находится в районе 58–60 шагов. Следовательно, если агенту удаётся выйти на правильный маршрут, он достигает станции сравнительно быстро, но такие эпизоды остаются редкими.




Рисунок 3 — Эмпирическая функция распределения времени успеха (CDF) для успешных эпизодов в итоговом тестировании

На графике фактически представлена только кривая Prospect-агента, поскольку у рационального и риск-чувствительного агентов в итоговом тесте успешные эпизоды отсутствовали.

Тепловые карты финального заряда позволяют увидеть, в каких областях пространства завершается большинство эпизодов. Для рационального и риск-чувствительного агентов заметна большая доля завершений вдали от станции зарядки, что соответствует нулевой доле успеха. Для Prospect-агента распределение финального заряда более благоприятно вблизи правой части карты, то есть ближе к станции. Это согласуется с тем, что именно этот агент сумел показать ненулевую долю успешных эпизодов.




Рисунок 4 — Тепловая карта финального заряда для рационального агента




Рисунок 5 — Тепловая карта финального заряда для поведенческого агента Prospect Q-learning




Рисунок 6 — Тепловая карта финального заряда для риск-чувствительного агента

Показательные траектории подтверждают общую картину. Большая часть запусков проходит в левой половине карты: агентам трудно преодолеть область препятствий и постепенно выйти к цели в правом верхнем секторе. Даже у Prospect-агента первые записанные траектории могут быть неуспешными, поскольку в коде сохраняются первые четыре тестовых эпизода, а не специально отобранные успешные примеры.




Рисунок 7 — Примеры тестовых траекторий рационального агента




Рисунок 8 — Примеры тестовых траекторий поведенческого агента Prospect Q-learning




Рисунок 9 — Примеры тестовых траекторий риск-чувствительного агента

Заключение

В ходе работы была реализована среда навигации дрона для варианта 1 и проведено сравнение трёх табличных RL-агентов. Эксперимент показал, что в данной постановке задачи наилучший практический результат продемонстрировал поведенческий агент Prospect Q-learning. Он оказался единственным методом, который в финальном тестировании дал ненулевую долю успешных эпизодов (8 %) и при этом не уступил рациональному агенту

по среднему расходу энергии.

Рациональный Q-learning и риск-чувствительный агент в выбранной конфигурации не смогли стабильно находить маршрут к станции. Судя по траекториям и кривым обучения, основная трудность заключается в сочетании редкой положительной награды, ограниченного времени, препятствий и стохастического ветра. В таких условиях субъективное усиление отрицательных исходов в рамках Prospect Theory оказалось полезнее, чем переход к глобально риск-аверсивному критерию.

Полученные результаты позволяют сделать вывод, что для данной среды преобразование мгновенной награды по теории перспектив лучше согласуется со структурой задачи, чем энтропийный риск-чувствительный критерий с $\eta = 0.5$. В дальнейшем улучшение качества можно ожидать за счёт более тонкой дискретизации состояния, выбора η по сетке $\{0.5, 1.0, 2.0\}$, изменения формы награды и использования более информативной стратегии исследования.