

**TOMSK
POLYTECHNIC
UNIVERSITY**



**ТОМСКИЙ
ПОЛИТЕХНИЧЕСКИЙ
УНИВЕРСИТЕТ**

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский Томский политехнический университет» (ТПУ)

Школа: **Инженерная школа информационных технологий и робототехники**
Направление подготовки: **09.04.01 Информатика и вычислительная техника**
Отделение школы (НОЦ): **Отделение информационных технологий**

Практическая работа №1
по дисциплине
Обучение с подкреплением, метаэвристики и нейроэволюция

Тема задания
Табличные агенты (рациональный, поведенческий и риск-чувствительный) для задачи навигации дрона

Студент

Группа	ФИО	Подпись	Дата
8BM52	Фань Синьюэ		25.05.2026

Преподаватель

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Старший преподаватель ОИТ, ИШИТР	Григорьев Д. С.			

Введение

Цель работы состояла в реализации двумерной среды навигации дрона и сравнении трёх табличных агентов обучения с подкреплением: рационального Q-learning, поведенческого Prospect Q-learning и риск-чувствительного Q-learning на основе энтропийной полезности.

Эксперимент выполнялся для варианта 1 методических указаний. В этой постановке движение дрона осложняется турбулентным ветром, наличием четырёх прямоугольных препятствий, ограниченным зарядом батареи и требованием достичь станции быстрой зарядки с достаточно высоким остаточным зарядом.

После предварительной версии работы эксперимент был расширен до нескольких независимых запусков. В итоговой версии используется $N_RUNS = 5$, а для каждого агента в каждом запуске выполняется 15000 обучающих эпизодов и 300 тестовых эпизодов. Это позволяет не ограничиваться одним случайным seed и осторожнее интерпретировать результаты.

1. Постановка задачи и параметры варианта 1

Рабочая область задаётся прямоугольником $X = [0, 24] \times [0, 12]$. Цель агента — управлять дроном так, чтобы он достиг круглой области станции зарядки с центром (21.5, 8.5) и радиусом 0.9, сохранив заряд батареи выше заданного порога.

Начальная позиция дрона генерируется из нормального распределения с математическим ожиданием (3.5, 6.0) и $\sigma = 1.8$, после чего координаты ограничиваются диапазонами $x \in [1.0, 7.0]$ и $y \in [2.0, 10.0]$. Компоненты ветра w_x и w_y выбираются из равномерного распределения $U(-0.11, 0.11)$ и обновляются каждые 15 шагов.

Таблица 1 — Основные параметры варианта 1

Параметр	Значение
Рабочая область	$[0, 24] \times [0, 12]$
Станция зарядки	центр (21.5, 8.5), радиус 0.9
Начальная позиция	$N((3.5, 6.0), \sigma^2 I)$, $\sigma = 1.8$, clip по x и y
Ветер	$w_x, w_y \sim U(-0.11, 0.11)$, обновление каждые 15 шагов
Препятствия	4 прямоугольника O1–O4
Скорости	$\{0.10, 0.25, 0.40, 0.60\}$
Дискретизация	$14 \times 14 \times 12 \times 4 = 9408$ состояний
Число действий	16 дискретных действий
Успех	вход в станцию, $b > 0.90$, $t \leq 140$
Провал	$b < 0.04$ или $t \geq 200$




Рисунок 1 — Конфигурация среды для варианта 1: стартовая область, препятствия и станция зарядки

2. Модель среды и реализация MDP

Среда рассматривается как конечный марковский процесс принятия решений $M = (S, A, P, R, \gamma)$. Состояние включает относительное смещение до станции, текущий заряд батареи и наблюдаемую скорость: $s_t = (\Delta x_t, \Delta y_t, b_t, v_t)$. Непрерывные значения дискретизируются в индекс Q-таблицы.

В реализации действие задаётся парой направления и целевой скорости. Используются четыре ортогональных направления: вправо, вверх, влево и вниз. Для каждого направления доступны четыре режима целевой скорости,

что даёт 16 действий. Одинаковое множество действий используется всеми тремя агентами, поэтому сравнение между агентами остаётся корректным.

Динамика координат соответствует формуле $x_{t+1} = x_t + v_t \cos(\theta_t) + w_{x,t}$ и $y_{t+1} = y_t + v_t \sin(\theta_t) + w_{y,t}$. После вычисления предполагаемой новой позиции координаты дополнительно ограничиваются границами рабочей области.

Расход батареи является нелинейным и зависит от квадрата скорости, квадрата нормы ветра и линейного штрафа по скорости. Если дрон находится в зоне станции, к заряду добавляется $\text{charge_power} = 0.025$. Начальный заряд во всех эпизодах равен 1.0, что одинаково для всех агентов.

Модель столкновений реализована как «запрет входа». Если отрезок движения от текущей позиции до предполагаемой следующей позиции пересекает прямоугольное препятствие, координаты дрона не обновляются, но событие *collision* фиксируется и счётчик *collision_count* увеличивается. Такая модель одинакова для всех сравниваемых агентов.

3. Реализация табличных агентов

3.1. Рациональный Q-learning

Рациональный агент используется как базовая линия сравнения. Он максимизирует ожидаемую дисконтированную сумму наград. На каждом переходе применяется стандартное TD-обновление $Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_a Q(s',a) - Q(s,a)]$ для нетерминальных состояний. Для терминального перехода будущая часть не добавляется.

3.2. Prospect Q-learning

Поведенческий агент отличается от рационального способом восприятия мгновенной награды. Перед обновлением Q-таблицы *reward* преобразуется функцией теории перспектив: положительные награды сжимаются степенью α_p , а отрицательные усиливаются коэффициентом

потерь λ_p . В работе использованы параметры $\alpha_p = 0.88$, $\beta_p = 0.88$, $\lambda_p = 2.35$.

3.3. Risk-sensitive Q-learning

Риск-чувствительный агент реализован через экспоненциальное преобразование $U(s,a) = \exp(-\eta Q(s,a))$. Значение $\eta = 0.5$ выбрано как умеренный риск-аверсивный режим из допустимого множества $\{0.5, 1.0, 2.0\}$. При $\eta > 0$ агент сильнее штрафует неблагоприятные траектории и высокую дисперсию возврата.

Для всех трёх агентов используется одинаковый механизм выбора действий ϵ -greedy. В случае полного равенства нескольких максимальных Q-значений дополнительно применяется одинаковое для всех агентов tie-break правило `one_step_lookahead_score`. Оно не меняет награды и динамику среды, а только разрешает равенство между действиями.

4. Протокол эксперимента

Основной эксперимент проводился в режиме `repeated experiments`. Для каждого из пяти `seed` выполнялось независимое обучение трёх агентов. После обучения каждый агент тестировался на 300 эпизодах при $\epsilon = 0.005$. Тестовые эпизоды задавались детерминированными `seed`, поэтому агенты сравнивались на сопоставимых стартовых позициях и реализациях ветра.

Таблица 2 — Параметры обучения и тестирования

Параметр	Значение
N RUNS	5
RUN SEEDS	[100, 200, 300, 400, 500]
Train episodes per agent per run	15000
Test episodes per agent per run	300
γ	0.99
α	0.10
$\epsilon_{start} \rightarrow \epsilon_{min}$	1.0 $\rightarrow$ 0.01
ϵ_{decay}	0.997
test ϵ	0.005
optimistic Q0	5.0

В ходе обучения логировались суммарная награда, длина эпизода, число коллизий, финальный заряд батареи и факт успеха. Во время тестирования дополнительно сохранялись расход энергии, финальные координаты и несколько траекторий для визуализации.

5. Ключевые фрагменты кода и проверочный вывод

Листинг 1 — Основная конфигурация эксперимента

```
SEED = 42
FAST_DEBUG = False
OFFICIAL_N_RUNS = 5
RUN_SEEDS = [100, 200, 300, 400, 500]
USE_SAFE_DISTANCE_TIE_BREAK = True

COMMON_CFG = {
    "num_train_episodes": 15000,
    "num_test_episodes": 300,
    "gamma": 0.99,
    "alpha": 0.10,
    "epsilon_start": 1.0,
    "epsilon_min": 0.01,
    "epsilon_decay": 0.997,
    "test_epsilon": 0.005,
    "prospect_alpha": 0.88,
    "prospect_beta": 0.88,
    "prospect_lambda": 2.35,
    "risk_eta": 0.5,
    "optimistic_q0": 5.0,
}
```

Листинг 2 — Реализация модели столкновения «запрет входа»

```
def segment_hits_rect(x1, y1, x2, y2, rect):
    rx1, ry1, rx2, ry2 = rect
    if point_in_rect(x1, y1, rect) or point_in_rect(x2, y2, rect):
        return True
    edges = [(rx1, ry1, rx2, ry1), (rx2, ry1, rx2, ry2),
              (rx2, ry2, rx1, ry2), (rx1, ry2, rx1, ry1)]
    return any(segment_intersect(x1, y1, x2, y2, *e) for e in edges)

def _apply_dynamics(self, theta, target_v):
    wx, wy = self.wind
    self.v = target_v
    nx = clip(self.x + self.v * np.cos(theta) + wx, self.xmin, self.xmax)
    ny = clip(self.y + self.v * np.sin(theta) + wy, self.ymin, self.ymax)
    collision = segment_hits_any_obstacle(self.x, self.y, nx, ny,
                                          self.cfg["obstacles"])

    if collision:
        self.collision_count += 1
    else:
        self.x, self.y = nx, ny
    return collision
```

Листинг 3 — Обновления Rational и Prospect Q-learning

```
class RationalQLearningAgent(BaseTabularAgent):
    def update(self, state, action, reward, next_state, done):
        target = reward if done else reward + self.gamma * np.max(self.Q[next_state])
        self.Q[state, action] += self.alpha * (target - self.Q[state, action])

class ProspectQLearningAgent(BaseTabularAgent):
    def value_function(self, r):
```

```

    if r >= 0:
        return r ** self.alpha_p
    return -self.lambda_p * ((-r) ** self.beta_p)

def update(self, state, action, reward, next_state, done):
    subjective_reward = self.value_function(reward)
    target = subjective_reward if done else subjective_reward +
self.gamma * np.max(self.Q[next_state])
    self.Q[state, action] += self.alpha * (target - self.Q[state, action])

```

Листинг 4 — Risk-sensitive обновление в U-пространстве

```

class RiskSensitiveQLearningAgent(BaseTabularAgent):
    def update(self, state, action, reward, next_state, done):
        old_u = self.U[state, action]
        if done:
            log_target_u = -self.eta * reward
        else:
            min_next_u = max(np.min(self.U[next_state]), 1e-300)
            log_target_u = -self.eta * reward + self.gamma * np.log(min_next_u)
            target_u = np.exp(np.clip(log_target_u, -700, 700))
            new_u = np.clip((1.0 - self.alpha) * old_u + self.alpha * target_u,
                            1e-300, 1e300)
            self.U[state, action] = new_u
            self.Q[state, action] = -(1.0 / self.eta) * np.log(new_u)

```

Листинг 5 — Проверочный вывод среды

```

Начальный индекс состояния: 8540
Состояний всего: 9408
Действий всего: 16
Начальная позиция: (1.0, 3.656)
Начальный ветер: (0.05745, 0.06293)
Начальный заряд: 1.0
step=1, action=6, reward=-1.005, battery=0.996, collision=False, x=1.06, y=4.12
step=2, action=3, reward=-1.011, battery=0.989, collision=False, x=1.71, y=4.18
step=3, action=12, reward=-1.000, battery=0.988, collision=False, x=1.77, y=4.14

```

6. Результаты repeated experiments

Итоговые показатели рассчитывались по пяти независимым запускам. В таблице ниже приведены средние значения и стандартные отклонения. Метрика MeanSuccTime вычисляется только по успешным эпизодам; если в отдельном запуске успешных эпизодов не было, это учитывалось как отсутствие значения для данной метрики.

Таблица 3 — Агрегированные результаты: mean $\pm$ std по пяти запускам

Агент	Успех, %	Среднее время успеха	Средний расход энергии	Эпизоды с коллизией, %	Средний финальный заряд
Rational Q-learning	0.27 $\pm$ 0.43	119.67 $\pm$ 6.60	0.5523 $\pm$ 0.0587	42.93 $\pm$ 7.03	0.4521 $\pm$ 0.0573
Prospect Q-learning	0.60 $\pm$ 0.55	99.83 $\pm$ 24.71	0.5598 $\pm$ 0.0235	54.27 $\pm$ 9.95	0.4487 $\pm$ 0.0230
Risk-sensitive Q-learning	0.27 $\pm$ 0.28	117.00 $\pm$ 16.52	0.5245 $\pm$ 0.0459	34.27 $\pm$ 14.84	0.4795 $\pm$ 0.0439

Полученные результаты показывают, что задача остаётся сложной для табличных агентов. Средняя доля успеха мала у всех методов. Prospect Q-learning имеет наибольшую среднюю долю успешных эпизодов, однако абсолютное значение успеха остаётся низким, а разброс между запусками не позволяет утверждать устойчивое превосходство. Risk-sensitive агент показывает меньший средний расход энергии и меньшую среднюю долю эпизодов с коллизиями, что соответствует более осторожному поведению, но это не приводит к явному увеличению вероятности достижения станции.

Листинг 6 — Консольный вывод агрегированных результатов

Repeated runs aggregated results: mean $\pm$ std					
Agent		Success %	MeanSuccTime	MeanEnergy	
Rational Q-learning		0.27 $\pm$ 0.43	119.67 $\pm$ 6.60	0.5523 $\pm$ 0.0587	42.93 $\pm$ 7.03
Prospect Q-learning		0.60 $\pm$ 0.55	99.83 $\pm$ 24.71	0.5598 $\pm$ 0.0235	54.27 $\pm$ 9.95
Risk-sensitive Q-learning		0.27 $\pm$ 0.28	117.00 $\pm$ 16.52	0.5245 $\pm$ 0.0459	34.27 $\pm$ 14.84
	MeanBattery				

7. Анализ визуализаций

Визуализации ниже построены для первого запуска repeated experiments как репрезентативный пример поведения агентов. Количественные выводы в работе делаются по агрегированным результатам пяти запусков из таблицы 3.




Рисунок 2 — Кривые обучения агентов: скользящее среднее награды с окном 150 эпизодов

Кривые обучения большую часть времени находятся около -201, что соответствует эпизодам, завершённым по лимиту времени без достижения станции. Отдельные подъёмы кривых соответствуют редким успешным или менее штрафным траекториям. Стабильного роста качества политики у всех агентов не наблюдается, что подтверждает сложность задачи.




Рисунок 3 — Эмпирическая функция распределения времени успеха для успешных тестовых эпизодов

CDF времени успеха показывает распределение длины успешных эпизодов. Так как успешных эпизодов мало, эта визуализация используется только как дополнительная иллюстрация, а не как единственное основание для вывода о качестве агента.




Рисунок 4 — Тепловая карта финального заряда для Rational Q-learning




Рисунок 5 — Тепловая карта финального заряда для Prospect Q-learning




Рисунок 6 — Тепловая карта финального заряда для Risk-sensitive Q-learning

Тепловые карты показывают, в каких областях пространства заканчиваются тестовые эпизоды и какой остаточный заряд имеет дрон. У Risk-sensitive агента средний финальный заряд выше, что согласуется с меньшим расходом энергии. Однако более высокий остаточный заряд сам по себе не означает успешное достижение станции.




Рисунок 7 — Примеры тестовых траекторий Rational Q-learning




Рисунок 8 — Примеры тестовых траекторий Prospect Q-learning




Рисунок 9 — Примеры тестовых траекторий Risk-sensitive Q-learning

Траектории подтверждают, что основная трудность состоит в выходе из левой стартовой области и прохождении через область препятствий к станции в правом верхнем секторе. На отдельных эпизодах агенты могут двигаться в сторону цели, но часто застревают, долго обходят препятствия или завершают эпизод по лимиту шагов.

8. Статистическое сравнение

Методические указания требуют статистического сравнения по выбранной числовой метрике. В работе использован Welch t-test. Основной тест выполнен по расходу энергии, так как время успеха определено только для успешных эпизодов и содержит мало наблюдений.

Таблица 4 — Welch t-test по метрике расхода энергии

Сравнение	n1	n2	t	p	Вывод
Rational vs Prospect	1500	1500	-1.4254	0.154133	незначимо
Rational vs Risk-sensitive	1500	1500	5.2777	1.40136e-07	значимо
Prospect vs Risk-sensitive	1500	1500	6.7765	1.47678e-11	значимо

Таблица 5 — Welch t-test по времени успеха

Сравнение	n1	n2	t	p	Вывод
Rational vs Prospect	4	9	2.0622	0.0636522	незначимо
Rational vs Risk-sensitive	4	4	0.5250	0.632329	незначимо
Prospect vs Risk-sensitive	9	4	-0.4131	0.700399	незначимо

По расходу энергии различия между Risk-sensitive агентом и двумя другими агентами статистически значимы в рамках pooled episode-level t-test. Это согласуется с тем, что риск-чувствительный агент действует более консервативно и в среднем тратит меньше энергии. По времени успеха статистически значимых различий не обнаружено; кроме того, число успешных эпизодов мало, поэтому данную метрику следует интерпретировать

осторожно.

Следовательно, основной результат заключается не в уверенном превосходстве одного агента по всем критериям, а в различии характера поведения: Prospect Q-learning чаще достигает успеха в среднем по запускам, Risk-sensitive Q-learning экономнее и реже сталкивается с препятствиями, а Rational Q-learning служит базовой линией сравнения.

Заключение

В ходе работы была реализована табличная среда навигации дрона для варианта 1 и проведено сравнение трёх агентов: Rational Q-learning, Prospect Q-learning и Risk-sensitive Q-learning. Среда включает турбулентный ветер, четыре прямоугольных препятствия, нелинейный расход батареи, зарядку в области станции и дискретизацию состояния $14 \times 14 \times 12 \times 4$.

По сравнению с предварительной версией работа была расширена до пяти независимых запусков. Это показало, что задача является сложной для табличных методов: средняя доля успеха остаётся низкой у всех агентов. Prospect Q-learning имеет наибольшую среднюю долю успеха, но преимущество не следует трактовать как устойчивое из-за малого числа успешных эпизодов и заметного разброса между запусками.

Risk-sensitive агент показал меньший средний расход энергии и меньшую среднюю долю эпизодов с коллизиями. Это соответствует ожидаемому более осторожному поведению при $\eta = 0.5$, однако такая осторожность не привела к существенному росту вероятности достижения станции. Рациональный агент выступает как базовая линия сравнения и демонстрирует типичную проблему sparse reward в данной среде.

Общий вывод состоит в том, что все три метода реализованы и протестированы в единой среде, но качество табличного обучения ограничено сложностью пространства, редкой положительной наградой, препятствиями и стохастическим ветром. Для дальнейшего улучшения можно увеличить число

обучающих эпизодов, выполнить подбор η по сетке $\{0.5, 1.0, 2.0\}$, изменить форму награды или использовать более информативное представление состояния.

Список использованных источников

1. Методические указания к практической работе №1 «Табличные агенты (рациональный, поведенческий и риск-чувствительный) для задачи навигации дрона».
2. Sutton R. S., Barto A. G. Reinforcement Learning: An Introduction. 2nd ed. MIT Press, 2018.
3. Watkins C. J. C. H., Dayan P. Q-learning. Machine Learning, 1992.
4. Kahneman D., Tversky A. Prospect Theory: An Analysis of Decision under Risk. Econometrica, 1979.
5. Howard R. A., Matheson J. E. Risk-sensitive Markov decision processes. Management Science, 1972.